

# Szoftver mély neuronhálók alkalmazásához

## 2. előadás

Kovács Bálint, Varga Viktor  
ELTE IK Mesterséges Intelligencia Tanszék

# Előző órán


## A gépi tanulás lényege

- Egy feladatot nem a megoldó algoritmus leprogramozása segítségével oldunk meg.
- Helyette, egy **paraméteres modellhez keresünk** olyan **paramétereket**, melyekkel a modell megoldja a feladatot.
- Az ideális paramétereket a feladathoz tartozó mintapéldák segítségével találjuk meg.

# Előző órán - Gépi tanuláshoz ideális feladatok

- Ha közelítően optimális megoldás is megfelelő.
- Ha nem ismert konkrét algoritmus, ami megoldja a feladatot.
- Ha nem gazdaságos egyedi algoritmust fejleszteni a problémára.
- Ha a feladatot csak mintapéldák segítségével tudjuk formálisan definiálni.

**Hogyan definiáljuk azt, hogy “kutya”, vagy “kerékpár” mintapéldák nélkül?**



# Előző órán - Felügyelt tanulás

**Adott:** A tanítóminta (training set), input-címke párok halmaza

$$\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$$

$$x \in X \subset \mathbb{R}^n, y \in Y \subset \mathbb{R}^k$$

**Feladat:** A címke (az elvárt output) minél jobb becslése az inputból.

Azaz, keresünk olyan  $h_\theta$  függvényt (hipotézisfüggvényt), melyre:

$$h_\theta(x) = \hat{y} \approx y$$

# Előző órán - Felügyelt tanulás

a zárójeles felső index nem  
hatvány, hanem a minta  
elemeinek indexe

**Adott:** A tanítóminta (training set), input-címke párok halmaza

$$\{(x^{(1)}, y^{(1)}), \dots, (x^{(m)}, y^{(m)})\}$$

$$x \in X \subset \mathbb{R}^n, y \in Y \subset \mathbb{R}^k$$

**Feladat:** A címke (az elvárt output) minél jobb becslése az inputból.

Azaz, keresünk olyan  $h_\theta$  függvényt (hipotézisfüggvényt), melyre:

$$h_\theta(x) = \hat{y} \approx y$$

a hipotézisfüggvény  $x$  inputból becsli az  $y$   
címkét. A becslését “ $y$  kalap”-pal jelöljük.

# Előző órán - A felügyelt tanulás két fő feladata

**Regresszió:** A címkehalmaz összefüggő és végtelen

$$|Y| = \infty$$

**Példa:** Autók számának, vagy életkor becslése

**Klasszifikáció:** A címkehalmaz diszkrét és számossága véges

$$|Y| < \infty$$

**Példa:** Mintaelemek kategorizálása

- A lakosság számából eldönteni, hogy város-e, vagy falu egy adott település
- Mi a foglalkozása a képeken szereplő személyeknek?

# Ezen az órán - Regresszió

**Regresszió:** A címkehalmaz összefüggő és végtelen

$$|Y| = \infty$$


**Példa:** Autók számának, vagy életkor becslése

# Regresszió

**Példa:** Becsüljük meg az autók számát egy adott városban, ha ismerjük a város lakosságának számát.

**x:** Egy adott város lakosságának száma

**y:** Egy adott városban megtalálható autók száma



$$x^{(j)}, y^{(j)} \in \mathbb{R}$$




# Regresszió

**Példa:** Becsüljük meg az autók számát egy adott városban, ha ismerjük a város lakosságának számát.

**x:** Egy adott város lakosságának száma

**y:** Egy adott városban megtalálható autók száma

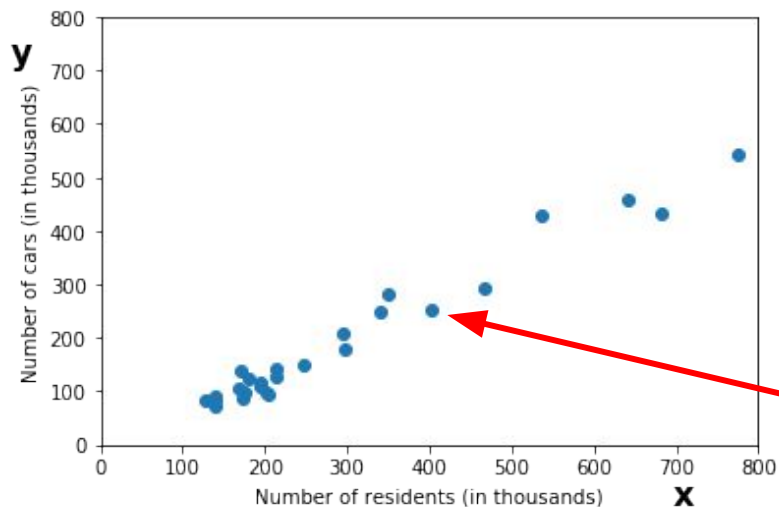
**Egy input változó és egy címke: a mintaelemek a címkével, kétdimenziós vektortérben (síkon) elhelyezkedő pontok**



$$x^{(j)}, y^{(j)} \in \mathbb{R}$$

# A minta ábrázolása

Cars and residents (Poland 2017)



$$x^{(j)}, y^{(j)} \in \mathbb{R}$$

	input	címke
	$x$ (egy adott város lakossága, ×1000)	$y$ (autók száma a városban, ×1000)
Varsó (j = 1)	1760	910
Krakkó (j = 2)	770	535
Szczecin (j = 3)	407	263
...	...	...


# Lineáris regresszió

## Hipotézisfüggvény:

Nagyon egyszerű (lineáris)  
hipotézisfüggvény:

$$y \approx \hat{y} = h_{\theta}(x) = \theta x$$

$\theta \in \mathbb{R}$  a hipotézisfüggvény  
paramétere, ebben az esetben az  
egyenes meredeksége lesz...



# Lineáris regresszió

## Hipotézisfüggvény:


Nagyon egyszerű (lineáris)  
hipotézisfüggvény:

$$y \approx \hat{y} = h_{\theta}(x) = \theta x$$

$\theta \in \mathbb{R}$  a hipotézisfüggvény  
paramétere, ebben az esetben az  
egyenes meredeksége lesz...

Keresünk egy olyan  $\theta$  paramétert, mellyel  
 $h(x)$  jól közelíti az igazi  $y$  címkéket!

Például a  $h(x) = 0.65 \cdot x$  hipotézis-  
függvény erre a konkrét mintára jól illeszkedik,  
így tehát egy jó paraméter a  $\theta = 0.65$ .



# Lineáris regresszió

Hogyan állapítjuk meg mennyire jó a becslés?

$$h_{\theta}(x) = \hat{y} \overset{?}{\approx} y$$

# Lineáris regresszió

Hogyan állapítjuk meg mennyire jó a becslés?

$$h_{\theta}(x) = \hat{y} \overset{?}{\approx} y$$

**J költségfüggvény segítségével:**  $J : \theta \rightarrow \mathbb{R}_{\geq 0}$

A költségfüggvény megadja, hogy mennyire tér el a valódi címke és a becslésünk adott paraméter értékek esetén.

# Lineáris regresszió

Hogyan állapítjuk meg mennyire jó a becslés?

$$h_{\theta}(x) = \hat{y} \overset{?}{\approx} y$$

**J költségfüggvény segítségével:**  $J : \theta \rightarrow \mathbb{R}_{\geq 0}$

A költségfüggvény megadja, hogy mennyire tér el a valódi címke és a becslésünk adott paraméter értékek esetén.

Akárhány dimenziós a címkénk és akárhány mintaelem van a tanítóhalmazban, **a költség mindenképpen egyetlen szám kell, hogy legyen.** Így egyértelműen össze tudunk hasonlítani két hipotézisfüggvényt / paraméterkombinációt.

# Lineáris regresszió

Lineáris regresszió esetén a költségfüggvény:

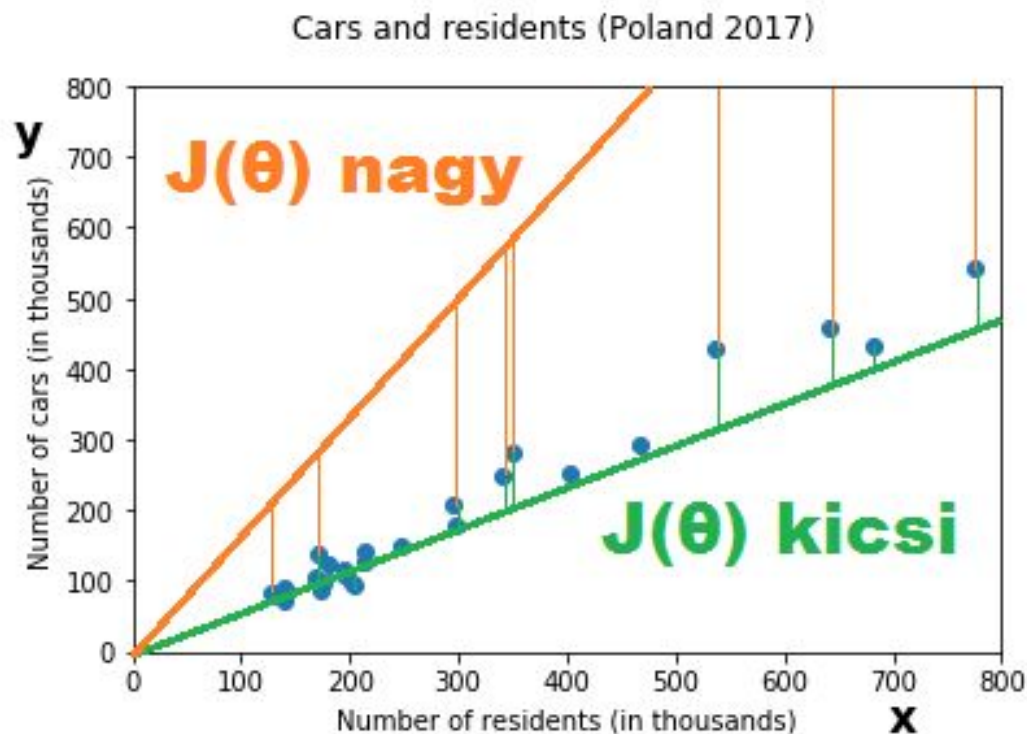
$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m \overbrace{(h_{\theta}(x^{(j)}) - y^{(j)})^2}^{\hat{y}^{(j)}}$$

... azaz, a hipotézisfüggvény által becsült címkék és az igazi címkék különbségének a négyzete, átlagolva a mintaelemek felett:

**MSE (Mean Squared Error, átlagos négyzetes eltérés)**



# Lineáris regresszió



# Lineáris regresszió

A feladat tehát:  $\theta^* = \underset{\theta}{\operatorname{argmin}} J(\theta)$

→ keressük azt az **optimális paramétert** ( $\theta^*$ ), mellyel minimális a költség, azaz a címke predikciónk átlagos négyzetes eltérése az igazi címkétől.

$$\begin{aligned}\theta^* &= \underset{\theta}{\operatorname{argmin}} \frac{1}{2m} \sum_{j=1}^m (h_{\theta}(x^{(j)}) - y^{(j)})^2 = \\ &= \underset{\theta}{\operatorname{argmin}} \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2\end{aligned}$$

# Lineáris regresszió - megoldás

**A feladat:**  $\theta^* = \underset{\theta}{\operatorname{argmin}} J(\theta)$

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (h_{\theta}(x^{(j)}) - y^{(j)})^2 = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

**Hogy néz ki a költségfüggvény kifejtve?**

# Lineáris regresszió - megoldás

**A feladat:**  $\theta^* = \operatorname{argmin}_{\theta} J(\theta)$

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (h_{\theta}(x^{(j)}) - y^{(j)})^2 = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$


**Hogy néz ki a költségfüggvény kifejtve?**

$x, y$  ismert konstansok, hiszen a tanítóhalmazban vannak.  
 $\theta$  ismeretlen.  
→ **J kvadratikusan  $\theta$  szerint.**

# Lineáris regresszió - megoldás

**J költségfüggvény kvadratikus.**


Mivel a  $\theta$  paraméter most csak egyetlen szám, így J parabola:



$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

# Lineáris regresszió - megoldás


A feladat:  $\theta^* = \operatorname{argmin}_{\theta} J(\theta)$



# Lineáris regresszió - megoldás


Hogyan jutunk el  $\theta'$  -ből  $\theta^*$  -ba?

Változtassunk  $\theta'$  -n, úgy, hogy  $J(\theta'') < J(\theta')$  !



# Lineáris regresszió - megoldás


Honnan tudjuk, hogy merre kell lépünk, hogy a költség csökkenjen?





# Lineáris regresszió - megoldás

Honnan tudjuk, hogy merre kell lépünk, hogy a költség csökkenjen?




**Egyetlen paraméter esetén** nem nehéz: pl. megnézzük, hogyan változik a költség, ha  $\theta'$ -t csökkentjük, vagy növeljük egy kicsivel. Lépünk arra, amerre csökken a költség!

Azonban, **ha majd több paraméterünk lesz**, a kipróbálandó lépésirányok száma exponenciálisan nő a paraméterek számával...

**Használjunk kifinomultabb módszert!**

# Lineáris regresszió - megoldás

Honnan tudjuk, hogy merre kell lépünk, hogy a költség csökkenjen?




Nézzük meg merre lejt leginkább a költségfüggvény az aktuális paraméterértékben állva!

Mi adja meg  $J$  meredekségét egy adott  $\theta$  pontban?

# Lineáris regresszió - megoldás

Honnan tudjuk, hogy merre kell lépünk, hogy a költség csökkenjen?



Nézzük meg merre lejt leginkább a költségfüggvény az aktuális paraméterértékben állva!

Mi adja meg  $J$  meredekségét egy adott  $\theta$  pontban?

**$J$  deriváltja a  $\theta$  pontban.**


# Lineáris regresszió - megoldás

**Mi egy függvény deriváltja?**

# Lineáris regresszió - megoldás

Mi egy függvény deriváltja?

$$f'(z) = \lim_{a \rightarrow 0} \frac{f(z+a) - f(z)}{a}$$




# Lineáris regresszió - megoldás

Mi egy függvény deriváltja?

$$f'(z) = \lim_{a \rightarrow 0} \frac{f(z+a) - f(z)}{a}$$


**f függvény deriváltja a z pontban**  
a függvénygörbe z-beli érintőjének  
meredeksége.

A derivált a differenciahányados  
határértékével van definiálva,  
feltéve, ha az létezik és véges.



# Lineáris regresszió - megoldás

Honnan tudjuk, hogy merre kell lépünk, hogy a költség csökkenjen?



Lépünk  $\theta$ -val abba az irányba, amerre a legjobban lejt a költségfüggvény felülete.

Ehhez ki kell számolnunk a  $J$  költségfüggvény deriváltját.

# Lineáris regresszió - megoldás

A költségfüggvény deriváltja:

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

$$\frac{\partial}{\partial \theta} J(\theta) = ?$$



# Lineáris regresszió - megoldás

A költségfüggvény deriváltja:

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

$$\frac{\partial}{\partial \theta} J(\theta) = ?$$

**Ne feledjük:**  $x$ ,  $y$  ismert értékek a tanítóhalmazból, egyedül  $\theta$  az ismeretlen.

# Lineáris regresszió - megoldás

A költségfüggvény deriváltja:

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

$$\begin{aligned} \frac{\partial}{\partial \theta} J(\theta) &= \frac{1}{2m} \sum_{j=1}^m 2 \cdot (\theta x^{(j)} - y^{(j)}) \cdot (\theta x^{(j)} - y^{(j)})' = \\ &= \frac{1}{m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)}) x^{(j)} \end{aligned}$$

# Lineáris regresszió - megoldás

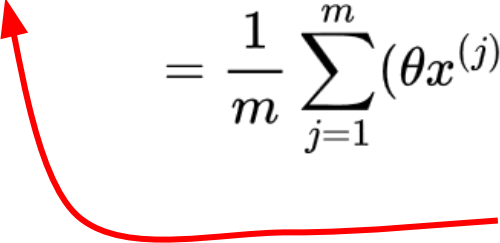
A költségfüggvény deriváltja:

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)})^2$$

**Összetett függvények deriválási szabálya** (láncszabály):

$$f(g(z))' = f'(g(z)) \cdot g'(z)$$


$$\frac{\partial}{\partial \theta} J(\theta) = \frac{1}{2m} \sum_{j=1}^m 2 \cdot (\theta x^{(j)} - y^{(j)}) \cdot (\theta x^{(j)} - y^{(j)})' =$$

$$= \frac{1}{m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)}) x^{(j)}$$


**Leibniz-féle jelölés a parciális deriválásra:**  $J$  deriváltja  $\theta$  szerint. Itt még csak egy változónk van ( $\theta$ ), így nem kérdés, hogy mi szerint deriválunk...

# Lineáris regresszió - megoldás

## Gradiensmódszer (gradient descent)

Iteratívan lépegetünk  $\theta$ -val, abba az irányba, amerre a legnagyobb a lejtése a költségfüggvénynek az aktuális  $\theta$ -ban.

```
repeat until convergence {  
     $grad := \frac{\partial}{\partial \theta} J(\theta)$   
     $\theta := \theta - \alpha \cdot grad$   
}
```

# Lineáris regresszió - megoldás

## Gradiensmódszer (gradient descent)


Iteratívan lépegetünk  $\theta$ -val, abba az irányba, amerre a legnagyobb a lejtése a költségfüggvénynek az aktuális  $\theta$ -ban.

repeat until convergence {

$$grad := \frac{\partial}{\partial \theta} J(\theta)$$

$$\theta := \theta - \alpha \cdot grad$$

}

$$\frac{\partial}{\partial \theta} J(\theta) = \frac{1}{m} \sum_{j=1}^m (\theta x^{(j)} - y^{(j)}) x^{(j)}$$


# Lineáris regresszió - megoldás

## Gradiensmódszer (gradient descent)

Iteratívan lépegetünk  $\theta$ -val, abba az irányba, amerre a legnagyobb a lejtése a költségfüggvénynek az aktuális  $\theta$ -ban.

repeat until convergence {

$$grad := \frac{\partial}{\partial \theta} J(\theta)$$

$$\theta := \theta - \alpha \cdot grad$$

}

**J gradiense:** J legnagyobb emelkedése irányába mutató vektor; elemei J adott pontbeli parciális deriváltjai (itt még csak egyelemű)

**alfa:** tanulási ráta (learning rate); a lépések mérete skálázható vele

# Lineáris regresszió - megoldás

## Gradiensmódszer (gradient descent)

Iteratívan lépegetünk  $\theta$ -val, abba az irányba, amerre a legnagyobb a lejtése a költségfüggvénynek az aktuális  $\theta$ -ban.


repeat until convergence {

$$grad := \frac{\partial}{\partial \theta} J(\theta)$$

$$\theta := \theta - \alpha \cdot grad$$



}

A gradienst **kivonjuk** az aktuális paraméterértékből, hiszen a legnagyobb lejtést keressük.



# Lineáris regresszió - megoldás

A gradiensmódszer alkalmazása,  $T = 0$  (az első lépés előtt)





A kezdeti  $\theta$  -t véletlenszerűen választottuk.





# Lineáris regresszió - megoldás

A gradiensmódszer alkalmazása,  $T = 1$




# Lineáris regresszió - megoldás

A gradiensmódszer alkalmazása,  $T = \langle \text{sok} \rangle$



# Lineáris regresszió - megoldás

A költség alakulása a gradiensmódszer alkalmazása során




# Lineáris regresszió - megoldás

Mit értünk el?

Betanítottunk egy egyszerű (lineáris) regressziós modellt.

Új, címkézetlen mintaelemekre fogunk tudni címkét becsülni.




# Lineáris regresszió - megoldás

Mit értünk el?

Betanítottunk egy egyszerű (lineáris) regressziós modellt.


Új, címkézetlen mintaelemekre  
fogunk tudni címkét becsülni.

Például **egy 550 ezer lakosú városra**  
 **$0.6768 * 550\,000 = 372\,240$  autót becslünk.**




# Lineáris regresszió - megoldás

Mi hiányzik?



# Lineáris regresszió - megoldás

Mi hiányzik?



Tegyük fel, hogy minden város, függetlenül a lakosságának számától beszerez 300 ezer autót tartalékba...

**Erre a mintára nem illeszkednek jól az origón átmenő egyenesek.**

# Lineáris regresszió - megoldás

## Mi hiányzik?

Az eddigi modellünk túlzottan limitált. A hipotézisfüggvény egy olyan egyenes volt, amely az origón kellett, hogy átmenjen...

A meredekség mellé egy konstans (bias / intercept) paramétert is bevezetünk.

**Eddigi hipotézis:**  $h(x) = \theta x = \hat{y} \approx y$


**Új hipotézis:**  $h(x) = \theta_1 x + \theta_0 = \hat{y} \approx y$



# Lineáris regresszió

Az új hipotézisfüggvény:  $y \approx \hat{y} = h(x) = \theta_1 x + \theta_0$

$$\theta_1, \theta_0 \in \mathbb{R}$$




# Lineáris regresszió

Az új hipotézisfüggvény:  $y \approx \hat{y} = h(x) = \theta_1 x + \theta_0$

$$\theta_1, \theta_0 \in \mathbb{R}$$

$\theta_1$  az egyenes meredeksége,  
 $\theta_0$  pedig az az érték, ahol az  
egyenes metszi az y tengelyt  
(bias / intercept).



# Lineáris regresszió - megoldás

A költségfüggvény továbbra is **MSE** (Mean Squared Error):

$$J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\overbrace{h_{\theta}(x^{(j)})}^{\hat{y}^{(j)}} - y^{(j)})^2$$


A hipotézisfüggvény viszont megváltozott.

**Hogy fog kinézni a költségfüggvény grafikonja?**

# Lineáris regresszió - megoldás

**J költségfüggvény továbbra is kvadratikus.**

Mivel már két paraméterünk van, J egy elliptikus paraboloid:



$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{j=1}^m \overbrace{(\theta_1 x^{(j)} + \theta_0)}^{\hat{y}^{(j)}} - y^{(j)} )^2$$

# Lineáris regresszió - megoldás

**Hogyan változtassuk a paramétereket, hogy a költség csökkenjen?**

Használjuk a gradiens módszert: lépegezzünk a legnagyobb meredekségű lejtés irányába.

Ezt az irányt egy adott pontban a **gradiens** vektor fogja megadni, melynek elemei a  $J$  **költségfüggvény** parciális deriváltjai az egyes paraméterek szerint.

# Lineáris regresszió - megoldás

**A költségfüggvény parciális deriváltjai:**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = ?$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = ?$$

# Lineáris regresszió - megoldás

**A költségfüggvény parciális deriváltjai:**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)}) \cdot x^{(j)}$$

# Lineáris regresszió - megoldás

A költségfüggvény parciális deriváltjai:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})^2$$

$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)}) \cdot x^{(j)}$$

A parciális deriváláskor a függvényt az egyik változó szerint deriváljuk. Ekkor a többi változót **konstansként kezeljük**.

érintő meredeksége  **$\theta_0$**  irányban

érintő meredeksége  **$\theta_1$**  irányban



# Lineáris regresszió - megoldás

**Gradiens módszer algoritmus a két paraméter esetén:**

repeat until convergence    {

$$grad_0 := \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$grad_1 := \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \theta_0 - \alpha \cdot grad_0$$

$$\theta_1 := \theta_1 - \alpha \cdot grad_1$$

}

# Lineáris regresszió - megoldás

Gradiens módszer algoritmus két paraméter esetén:

repeat until convergence {

$$grad_0 := \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$grad_1 := \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \theta_0 - \alpha \cdot grad_0$$

$$\theta_1 := \theta_1 - \alpha \cdot grad_1$$

}



$$\frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)})$$

$$\frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{j=1}^m (\theta_1 x^{(j)} + \theta_0 - y^{(j)}) \cdot x^{(j)}$$

**alfa:** tanulási ráta (learning rate); a lépések mérete skálázható vele

# Lineáris regresszió - megoldás



A gradiens módszer alkalmazása,  $T = 0$  (az első lépés előtt)



A kezdeti  $(\theta_0, \theta_1)$ -t véletlenszerűen választottuk.



# Lineáris regresszió - megoldás

## A gradiens módszer alkalmazása, $T = 1$




# Lineáris regresszió - megoldás

A gradiens módszer alkalmazása,  $T = \langle \text{sok} \rangle$



# Lineáris regresszió - megoldás


**Garantált-e, hogy gradiens módszerrel megtaláljuk a lineáris regresszió optimális (minimális költségű) megoldását?**



# Lineáris regresszió - megoldás

**Garantált-e, hogy gradiens módszerrel megtaláljuk a lineáris regresszió optimális (minimális költségű) megoldását?**

Megfelelően kicsi lépésméret (alfa) esetén igen.



# Lineáris regresszió - megoldás

Garantált-e, hogy gradiens módszerrel megtaláljuk **tetszőleges költségfüggvény** globális minimumát?



# Lineáris regresszió - megoldás

Garantált-e, hogy gradiens módszerrel megtaláljuk **tetszőleges költségfüggvény** globális minimumát?

Nem. Eljuthatunk az egyik lokális minimum pontba, de amennyiben a költségfüggvény nem konvex, akkor nem garantált, hogy ez a globális minimum lesz.

# Lineáris regresszió - megoldás

Garantált-e, hogy gradiens módszerrel megtaláljuk **tetszőleges költségfüggvény** globális minimumát?

Nem. Eljuthatunk az egyik lokális minimum pontba, de amennyiben a költségfüggvény nem konvex, akkor nem garantált, hogy ez a globális minimum lesz.

**Vak hegymászó:** Le szeretne jutni a völgy legmélyebb pontjába, de csak azt érzi, hogy milyen irányban lejt leginkább a terep a talpa alatt...

# Lineáris regresszió - megoldás

Garantált-e, hogy gradiens módszerrel megtaláljuk **tetszőleges költségfüggvény** globális minimumát?

Nem. Eljuthatunk az egyik lokális minimum pontba, de amennyiben a költségfüggvény nem konvex, akkor nem garantált, hogy ez a globális minimum lesz.

**A lineáris regresszió nem csak iteratív, de egzakt módon is megoldható.** Lásd őszi félév 1. óra, vagy NumMód2...

# Lineáris regresszió - megoldás

**Miért pont négyzetes hibát használtunk költségként?**

(Miért nem mondjuk abszolútértékes hibát?)

# Összefoglalás

- **Gépi tanulásra ideális feladatok:** Ismeretlen (hatékony) megoldó-algoritmus, esetleg maga a feladat sem definiálható formálisan (helyette címkézett adathoz igazítunk egy paraméteres modellt).
- **Felügyelt tanulás:** Input-címke párok, az inputból tanuljuk megbecsülni a címkét.
- **Regresszió:** Mintaelemek címkéje folytonos.
- **Lineáris regresszió:** Megpróbáljuk a címkéket az input lineáris függvényeként felírni, majd keressük az egyenes azon paramétereit melyekkel a legjobban közelíthetők az igazi címkék.